


# 資料視覺化



國立宜蘭大學資訊工程系  
吳政瑋 助理教授

[wucw@niu.edu.tw](mailto:wucw@niu.edu.tw)



# 教學目標

---

- 了解資料視覺化的目的
- 了解常見的資料視覺化圖表
- 了解如何以軟體及工具製作圖表


# 眼力大考驗


假設發生火警，在煙霧彌漫中，你衝到門口，在那裡你看到緊急出口標語牌...

離開辦公室，右轉，有一條300公尺長的走廊直走到底，你會看到一間大會議室。向左轉，還有一條360公尺的走廊直走到底，在你的左手邊有一個火警警報器，旁邊是電梯；右手邊有一座樓梯。不要走到電梯；右轉，從另一條360公尺長的走廊直走到底，左轉進入樓梯間。走下兩階樓梯後，從樓梯底部的門離開大樓。

# 眼力大考驗


假設發生火警，在煙霧彌漫中，你衝到門口，在那裡你看到緊急出口標語牌...






# 資料視覺化的目的

- 資料視覺化(Data Visualization)是要用圖形或是表格的方式來呈現資料。一個成功的視覺化圖表，能夠清楚的呈現資料的特性，以及資料間或是屬性值的關係，而且可以輕易的讓人看圖示意。
- 在日常生活中，視覺化的圖表可以用來解釋氣象、經濟及選舉的預測結果。
- 有時會將資料探勘(Data Mining)的視覺化技術稱為視覺化資料探勘(Visual Data Mining)。



# 敘述性統計(Descriptive Statistics)

- 敘述性統計(Descriptive Statistics)在資料探勘領域中，又稱為探索式資料分析 (Exploratory Data Analysis，簡稱EDA)。
- EDA是由有統計界畢卡索之稱的Tukey所提出，主要概念是透過敘述性統計、統計繪圖、視覺化等快速簡易的方式，從各種面向先了解資料的狀況，以利後續分析。



# EDA常見的資料圖表類型


- 類別屬性

- 長條圖(Bar Chart)
- 圓形圖(Pie Chart)


- 數值屬性

- 莖葉圖(Stem Plot / Stem-and-leaf plot)
- 直方圖(Histogram)
- 盒型圖(Box Plot)
- 散佈圖(Scatter Plot)
- 折線圖(Line Chart)

# 長條圖(Bar Chart)




# 圓形圖(Pie Chart)



## 注意事項:

1. 使用 Pie chart 可顯示每一類所佔的百分比
2. Bar chart 可作到相同的效果
3. 換算成百分比的過程可能產生誤差



# 莖葉圖(Stem-and-Leaf Plot)

- 普林斯頓大學John Tukey教授於1977年所發展。
- 莖葉圖最適合**二位數資料**之呈現，如：考試成績。
- 莖葉圖的製作是將每個觀察值切割為**莖**及**葉**兩部份，中間以垂直線隔開。**莖**為觀察值中間**十位數或以上之數字**；**葉**則為**個位數**的數字。

# 莖葉圖(Stem-and-Leaf Plot)

Frequency	Stem & Leaf	
2.00	2 .	11
2.00	2 .	23
8.00	2 .	44445555
11.00	2 .	6666666777
16.00	2 .	8888899999999999
8.00	3 .	00011111
5.00	3 .	22333
8.00	3 .	44445555
8.00	3 .	66667777
10.00	3 .	8888899999
5.00	4 .	11111
1.00	4 .	2
1.00	4 .	5
1.00	4 .	7
6.00	4 .	888889
2.00	5 .	00
2.00	Extremes ( $\geq 56$ )	

Stem width: 莖的部份

葉的部份


# 莖葉圖(Stem-and-Leaf Plot)

- 莖葉圖的主要優點為兼具**次數分配表**與**長條圖**之雙重優點。
- 莖葉圖**不會失去原資料值**，所有原資料值在莖葉圖上一目瞭然。

Frequency	Stem &	Leaf
2.00	2 .	11
2.00	2 .	23
8.00	2 .	44445555
11.00	2 .	66666666777
16.00	2 .	8888999999999999
8.00	3 .	00011111
5.00	3 .	22333
8.00	3 .	44445555
8.00	3 .	66667777
10.00	3 .	8888999999
5.00	4 .	11111
1.00	4 .	2
1.00	4 .	5
1.00	4 .	7
6.00	4 .	888889
2.00	5 .	00
2.00	Extremes	(>=56)

Stem width: 莖的部份  
葉的部份


# 直方圖(Histogram)



# 直方圖 對稱分佈與偏斜分佈


## ■ 對稱分佈(Symmetric Distribution)

- 直方圖的右邊大約為左邊的鏡像




## ■ 偏斜分佈


- 右偏(Skew to the right): 右邊延展比左邊遠
- 左偏(Skew to the left)



# 箱型圖(Box Plot)


- 箱型圖(Box Plot)，又稱盒型圖、盒鬚圖、盒式圖、盒狀圖或箱線圖。
- 箱形圖於1977年由美國著名統計學家 John Tukey 發明。它為五數綜合的圖形化表示法，能顯示出一組數據的最大值、最小值、中位數、及上下四分位數，其可用來了解資料的分佈情況，並判斷是否存在離群值(Outlier)。





# 全距(Range)與四分位數(Quartiles) (Cont. 1/2)

- 全距(Range)，即一組觀測值的**最大值減去最小值**。
- 第一四分位數( $Q_1$ )，又稱「**上四分位數**」，等於該樣本中所有數值由小到大排列後**第25%**的數字。
- 第二四分位數( $Q_2$ )，又稱「**中位數**」，等於該樣本中所有數值由小到大排列後**第50%**的數字。
- 第三四分位數( $Q_3$ )，又稱「**下四分位數**」，等於該樣本中所有數值由小到大排列後**第75%**的數字。




# 四分位距與四分位差

---


- 四分位距(Interquartile-range ; IQR)
  - 計算方式： $Q3 - Q1$
  
- 四分位差(Quartile Deviation ; QD)
  - 計算方式： $(Q3 - Q1)/2$


# 全距、四分位數、四分位距的 視覺化圖形



# 百分位數(Percentile)

- 第  $p$  百分位數(The  $p$ -th Percentile)
  - 有  $p\%$  的資料，其值低於  $p$ -th percentile
- 舉例說明
  - 若  $P_{30}$  等於 60，則資料組中有 30% 的資料低於 60 分。





# 五數綜合(Five-Number Summary)

- 五數綜合

- 最大值(Maximum)
- 第一四分位數(First Quartile)
- 中位數(Median)
- 第三四分位數(Third Quartile)
- 最小值(Minimum)


# 箱型圖上的離群值與極端值

## ■ 離群值(Outlier)


- $(Q1 - 1.5 \times IQR) \sim (Q1 - 3 \times IQR)$
- $(Q3 + 1.5 \times IQR) \sim (Q3 + 3 \times IQR)$

## ■ 極端值(Extreme Outlier)

- 值小於  $Q1 - 3 \times IQR$  或
- 值大於  $Q3 + 3 \times IQR$





# 散佈圖(Scatter Plot)



# 條件散佈圖

## 散佈圖加入類別





# 正關聯、負關聯

---

- **正關聯(Positive associated)**

- 變數 X : 高於(低於)平均值
- 變數 Y : 高於(低於)平均值

- **負關聯(Negative associated)**

- 變數 X : 高於(低於)平均值
- 變數 Y : 低於(高於)平均值

# 相關性(Correlation)


## ■ 皮爾森相關係數(Pearson Correlation Coefficient)

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$


## ■ 性質

- 皮爾森相關係數的範圍介於 1~ -1 之間
- $r > 0$  : 正相關
- $r = 0$  : 無線性相關
- $r < 0$  : 負相關


# 皮爾森相關係數與散布圖關係




$$r = +1$$




$$0 < r < 1$$




$$r = 0$$



$$r = -1$$



$$-1 < r < 0$$




$$r = 0$$

# 散佈圖矩陣(Matrix Scatter Plot)


- 散佈圖矩陣由John and Paul Tukey 提出，它能讓人一眼就看到所有兩兩變數的相關性。

管理資訊-統計分析-資料庫成績矩陣圖




# 三維散佈圖(3D Scatter Plot)

管理資料-統計分析-資料庫成績3D圖



# 常態分布(Normal Distribution)


Normal Distribution



Different Means  
Same Standard Deviation



Same Mean  
Different Standard Deviations




Different Means  
Different Standard Deviations




# 經驗法則(The Empirical Rule)

## 又稱 68%-95%-99.73% 法則




- 經驗法則限制條件
  - 常態分配、單峰、對稱分布、鍾型分配
- 經驗法則
  - 68% 的資料落在  $\mu \pm \sigma$  範圍內
  - 95% 的資料落在  $\mu \pm 2\sigma$  範圍內
  - 97.7% 的資料落在  $\mu \pm 3\sigma$  範圍內

# 單峰對稱分布 (Unimodal Symmetric Distribution)




- 單峰對稱分布
  - 平均值 = 中位數 = 眾數

# 單峰左偏分布(Unimodal Skewed to Left Distribution)



- 單峰左偏分布
  - 平均值 < 中位數 < 眾數

# 單峰右偏分布(Unimodal Skewed to Right Distribution)



- 單峰右偏分布
  - 平均值 > 中位數 > 眾數

# 偏態係數(Skewness Coefficient)




## ■ 偏態係數公式：

$$g_1 = \frac{m_3}{m_2^{3/2}} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left( \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{3/2}}$$

$g_1 = 0$  : 對稱分佈

$g_1 > 0$  : 右偏分佈

$g_1 < 0$  : 左偏分佈





# 峰態係數(Kurtosis Coefficient)

- 峰態係數用來量測峰度高低的量數，可以反映資料的分佈形狀較為高聳或是扁平。

$$g_2 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2} - 3$$

$g_2 > 0$  : 高峽峰(Lepto Kurtosis)  
 $g_2 = 0$  : 常態峰(Normal Kurtosis)  
 $g_2 < 0$  : 低潤峰 (Platy Kurtosis)






# 機率密度函數 (Probability Density Function ; PDF)


- 紿一個平均值 $\mu$ 以及標準差 $\sigma$ ，我們可畫出一個常態分佈。
- 可以根據下列的**機率密度函式**公式，計算任意實數 $x_i$ 發生在這個分佈的機率。

$$: \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$



# 相對離差量數

- 相對離差量數
  - 變異係數(Coefficient of Variation ; CV)
  - 標準分數 Z-Score (Standard Score, Z-score)
  
- 變異係數
  - $CV = (\text{標準差}/\text{平均值}) \times 100\% = (\sigma/\mu) \times 100\%$




# 標準分數Z-Score (Standard Score, Z-score)

- 標準分數(Standard Score)，又稱 **Z-score**，中文稱為**Z-分數**或**標準化值**。
- 標準分數可藉由以下公式求出：

$$z = \frac{x - \mu}{\sigma}$$

- **Z-score** 特性
  - $Z\text{-score} < 0$ ：原始分數  $x$  小於平均數
  - $Z\text{-score} = 0$ ：原始分數  $x$  等於平均數
  - $Z\text{-score} > 0$ ：原始分數  $x$  大於平均數



# 離差量數 (Measure of Dispersion)

- 絶對離差量數
  - 全距(Range)
  - 四分位距(Interquartile-range；IQR)
  - 四分位差(Quartile Deviation；QD)
  - 平均差(Mean Deviation)
  - 標準差與變異數(Standard Deviation & Variance)
- 相對離差量數
  - 變異係數(Coefficient of Variation；CV)
  - Z-Score

# 教師資訊



- 姓名:吳政瑋 (小吳老師)
- 現職:宜大資工專案助理教授
- 學歷:成功大學資工博士
- 研究興趣:資料探勘、人工智慧、AIoT應用
- 通訊方式
  - 電子信箱:wucw@niu.edu.tw
  - 校內電話: (03)9317331
  - Line: silvemoonfox
  - Office: 格致大樓E405室
  - 數位學習園區
- 實驗室:AI與資料科學實驗室
  - <https://sites.google.com/view/cwwuadslab/>

# 意見交流

歡迎提供意見與指導!!

您的寶貴意見將使本系更進步!!