

關聯規則探勘



國立宜蘭大學資訊工程系
吳政瑋 助理教授
silvemoonfox@hotmail.com

關聯規則探勘 (Association Rule Mining)

Data Mining 範例: 啤酒與尿布

- <https://www.youtube.com/watch?v=2W-yq0lGnrc>




沃瑪以關聯分析技術找出颶風與草莓餅乾之關聯性


- <https://www.youtube.com/watch?v=rvij5kVttu0>



關聯規則探勘 (又稱：購物籃分析)



Shopping Baskets




Customer 1



Customer 2



Customer 3



Customer n

TID	Transaction
T_1	{Milk, Bread, Cereal}
T_2	{Milk, Bread, Sugar, Eggs}
T_3	{Milk, Bread, Butter}
T_4	{Sugar, Eggs}

Milk → Bread [75%, 100%]



關聯規則探勘之相關定義 (Cont. 1/2)

- **Item (項目)**
 - e.g., A, B, C, D, E, F
- **Itemset (項目集)**
 - e.g., {ABC}
- **Contain (包含)**
 - e.g., {AC} 包含於 T_1, T_2
 - e.g., $g(\{AC\}) = \{1, 2\}$
- **Subset (子集合)**
 - e.g., {ABC} 的子集合有 $\{\{A\}, \{B\}, \{C\}, \{AB\}, \{AC\}, \{BC\}, \{ABC\}\}$
- **Superset (超集合)**
 - e.g., {ABC} 為 $\{A\}, \{B\}, \{C\}, \{AB\}, \{AC\}, \{BC\}, \{ABC\}$ 的超集合
 - e.g., {ABCD} 為 {ABC} 的超集合

Transaction Database	
TID	Transaction
1	ABC
2	AC
3	AD
4	BEF

關聯規則探勘之相關定義 (Cont. 1/3)

■ Support Count (支持數)

- e.g., $SC(\{AC\}) = 2$

■ Support of Itemset (支持度)

- e.g., $sup(\{AC\}) = SC(\{AC\})/|D| = 2/4 = 50\%$

■ Frequent Itemset (頻繁項目集)

- 令 δ 為最小之持數門檻值 (*minimum support count threshold*)。若一個項目集 X 的支持數不亞於 δ ，則稱 X 為頻繁項目集(*frequent itemset*)；反之則稱 X 為非頻繁項目集 (*infrequent itemset*)。
- e.g., $\delta = 2$ ， $SC(\{AC\}) \geq \delta$ ， $\{AC\}$ 為頻繁項目集

Transaction Database	
TID	Transaction
1	ABC
2	AC
3	AD
4	BEF

關聯規則探勘之相關定義 (Cont. 2/3)

■ Frequent Itemset (頻繁項目集)

- 令 θ 為最小之持度門檻值 (*minimum support threshold*)。若一個項目集 X 的支持度不亞於 θ ，則稱 X 為頻繁項目集(*frequent itemset*)；反之則稱 X 為非頻繁項目集 (*infrequent itemset*)。
- e.g., $\theta = 50\%$, $sup(\{AC\}) \geq \theta$, $\{AC\}$ 為頻繁項目集

Transaction Database	
TID	Transaction
1	ABC
2	AC
3	AD
4	BEF

相關商品組合探勘技術可切割成兩大 主要步驟

輸入：

1. 交易資料庫
2. 使用者參數 θ

輸入：

1. 所有相關商品組合
2. 使用者參數 δ



相關商品組合探勘
演算法

關聯規則產生
演算法



輸出：

1. 所有的相關商品組合

輸出：

1. 所有的關聯規則

關聯規則探勘之相關定義 (Cont. 2/2)

■ Rule (規則)

- 一條規則的形式 $X \rightarrow Y$
- e.g., $\{A\} \rightarrow \{C\}$
- **Support of Rule (規則的支持度)**
 - $sup(X \rightarrow Y) = sup(XY)$
 - e.g., $sup(\{A\} \rightarrow \{C\}) = sup(\{AC\})$
- **Confidence of Rule (規則的信賴度)**
 - $conf(X \rightarrow Y) = SC(XY) / SC(X)$
 - e.g., $sup(\{A\} \rightarrow \{C\}) = SC(\{AC\}) / SC(\{A\}) = 2/3$
- **Association Rule (關聯規則)**
 - 若一條規則 $X \rightarrow Y$ 的支持度不亞於使用者自訂的最小之持度門檻值 θ ，且其信賴度不亞於使用者自訂的最小信賴度門檻值 (Minimum Confidence Threshold) δ ，則稱此規則為關聯規則。
 - $sup(X \rightarrow Y) \geq \theta$ and $conf(X \rightarrow Y) \geq \delta$

Transaction Database	
TID	Transaction
1	ABC
2	AC
3	AD
4	BEF

關聯規則探勘技術之相關定義

□ 規則的形式 為 $X \rightarrow Y$

- 例如： $\{A\} \rightarrow \{C\}$
- X 和 Y 皆為商品組合，且 $X \cap Y = \emptyset$
- X 稱為前項/左項
- Y 稱為後項/右項

關聯規則探勘技術之相關定義

□ 關聯規則

□ 定義：

1. 若一條規則 $X \rightarrow Y$ 發生的次數不亞於使用者自訂的最小之持度 θ ；
2. 而且，它的信賴程度不亞於使用者自訂的最小信賴程度 δ ；
3. 則稱 $X \rightarrow Y$ 為相關商品組合規則。

對每一個 FI 產生規則 舉例說明

Frequent Itemset	Count
{A}	2
{B}	3
{C}	3
{E}	3

Frequent Itemset	Count
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

Frequent Itemset	Count
{B, C, E}	2

- 頻繁項目集{AC}可產生兩條規則，這些規則的支持度相同
 - $\{A\} \rightarrow \{C\}$, $conf = SC(\{AC\})/SC(\{A\}) = 2/2 = 100\%$
 - $\{C\} \rightarrow \{A\}$, $conf = SC(\{AC\})/SC(\{C\}) = 2/3 = 66.6\%$

對每一個 FI 產生規則 舉例說明

Frequent Itemset	Count
{A}	2
{B}	3
{C}	3
{E}	3

Frequent Itemset	Count
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

Frequent Itemset	Count
{B, C, E}	2

- $\{BCE\}$ 可產生 $2^3 - 2$ 條規則，這些規則的支持度皆相同
 - $\{B\} \rightarrow \{CE\}$, $conf = SC(\{BCE\})/SC(\{B\}) = 2/3 = 66.6\%$
 - $\{C\} \rightarrow \{BE\}$, $conf = SC(\{BCE\})/SC(\{C\}) = 2/3 = 66.6\%$
 - $\{E\} \rightarrow \{BC\}$, $conf = SC(\{BCE\})/SC(\{E\}) = 2/3 = 66.6\%$
 - $\{CE\} \rightarrow \{B\}$, $conf = SC(\{BCE\})/SC(\{CE\}) = 2/2 = 100\%$
 - $\{BE\} \rightarrow \{C\}$, $conf = SC(\{BCE\})/SC(\{BE\}) = 2/3 = 66.6\%$
 - $\{BC\} \rightarrow \{E\}$, $conf = SC(\{BCE\})/SC(\{BC\}) = 2/3 = 66.6\%$


$$\theta = 2$$

編號	交易
10	ACD
20	BCE
30	ABCE
40	BE

1st scan →

Candidate Itemset	count
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

Frequent Itemset	Count
{A}	2
{B}	3
{C}	3
{E}	3




Frequent Itemset	Count
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

←

Candidate Itemset	count
{A, B}	1
{A, C}	2
{A, E}	1
{B, C}	2
{B, E}	3
{C, E}	2

2nd scan ←

Candidate Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}



Candidate Itemset
{B, C, E}

3rd scan →

Frequent Itemset	Count
{B, C, E}	2